Crypto Data Engineering

Crypto Data Engineering

DWH Pipeline und Dashboard MVP

Masterarbeit Projektstand

- Datum: 2026-02-23
- Fokus: Messwerte sichtbar machen, bevor Forecasting startet

---

Agenda

1. Problem und Zielbild
2. DWH Architektur und Datenfluss
3. KPI Definitionen und Qualitaetssicherung
4. Dashboard MVP und aktueller Stand
5. Risiken, offene Punkte, naechste Schritte

Problem und Zielbild

Problem

- Gleiche Kryptowaehrung wird auf verschiedenen Exchanges unterschiedlich gepreist.
- Datenqualitaet und Plattformstabilitaet unterscheiden sich stark.
- Ohne KPI-Layer ist ein fairer Exchange-Vergleich schwer.

Zielbild

- Reproduzierbare DWH-Pipeline fuer Markt- und Betriebsdaten.
- Vergleichbare KPIs pro Exchange und Symbol.
- Dashboard fuer schnelle Analyse von Preisabweichung und Plattformqualitaet.

Zielarchitektur (Uebersicht)

Pipeline Details (1/2)

Ingestion

- CCXT Websocket / Marktstream pro Exchange.
- Speicherung in SQLite mit Ingestion-Timestamp pro Tick.
- Operational Supervision fuer Worker und Reconnect.

Staging

- Taeglicher Export des letzten 24h Fensters.
- Entkopplung zwischen Online-Ingestion und Downstream-Transformation.

Pipeline Details (2/2)

Cleansing

- Resampling auf konsistentes Zeitraster.
- Fill-Strategien: observed, forward_fill, interpolation.
- Data-Quality Checks auf Nullwerte, Duplikate, Ausreisser.

Core

- KPI Views fuer Latency, Update-Frequenz, Disconnects, Price Deviation.
- Validierungsregeln mit SQL Assertions und Report-Ausgabe.

KPI Definitionen (Kernmetriken)

Plattformqualitaet

- Latency (ms): min / avg / max pro Exchange.
- Update Frequency (Hz): aus Tick-Intervall abgeleitet.
- Disconnect Count: Anzahl `disconnect` Events pro Zeitraum.

Preisabweichung

- `max_price_diff_abs`: maximale absolute Differenz zwischen Exchanges.
- `max_price_diff_pct`: maximale relative Differenz in Prozent.
- Zeitlich ausgerichtet ueber Bucket-Timestamps.

Mart Layer als Dashboard Contract

Verwendete Views:

- `vw_mart_dashboard_platform_quality_daily`
- `vw_mart_dashboard_price_deviation_daily`
- `vw_mart_dashboard_price_curve_24h_binance`

Prinzip: - KPI-Logik bleibt in SQL Views. - Dashboard liest nur konsumfertige Daten. - Keine ad-hoc KPI-Berechnung in der UI.

Dashboard MVP (Implementiert)

Bestandteile: - Symbol-Selector - 24h Price Curve (Binance Baseline) - Daily Price Deviation Snapshot - Daily Platform Quality Snapshot

Technik: - Streamlit App: `scripts/5_marts/dashboard_mvp_app.py` - Datenquelle: `data/core/core_kpi.db` mit Mart Views

---

Dashboard Laufzeitfluss

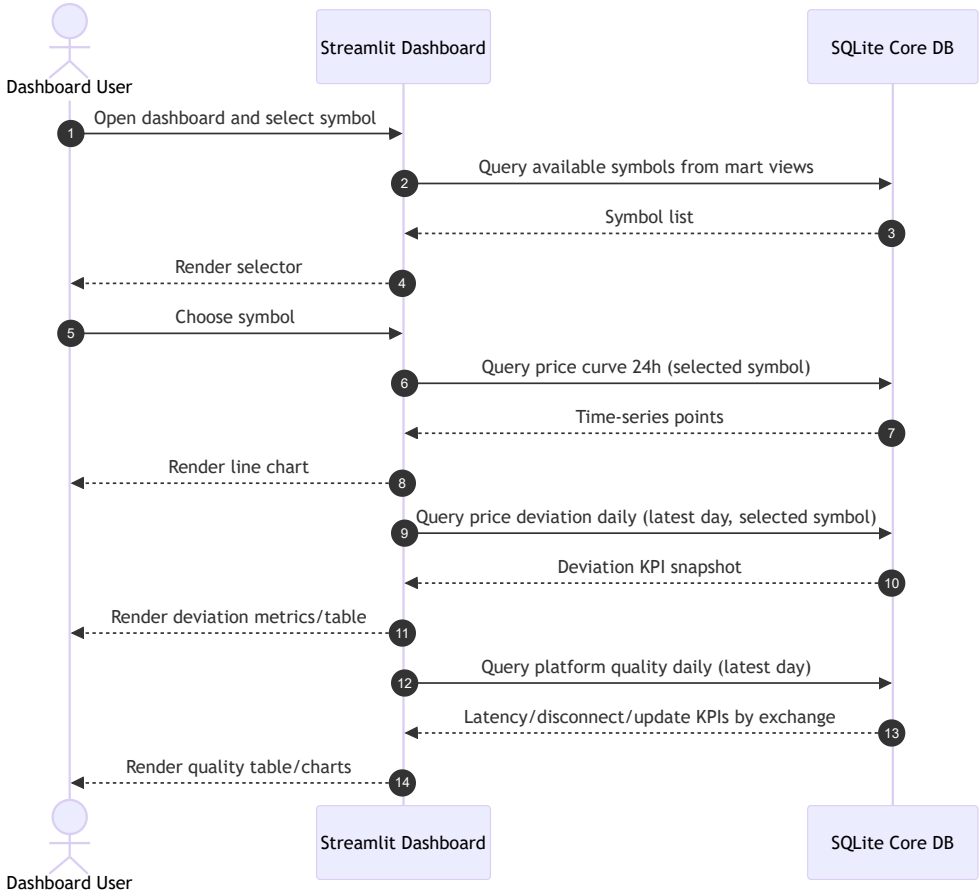

Bisherige Beobachtungen aus Messlaeufen

- Erste Volumenschaetzung: ca. `90 GB/Tag` (basierend auf 12h Vorlaufmessung).
- Exchange Coverage: nur ein Teil der CCXT-Exchanges liefert stabil Daten.
- Home-Network Betrieb kann Disconnect-KPIs verfaelschen.
- Staging Laufzeiten aktuell noch relativ hoch fuer schnelle Iterationen.

Quelle: - `docs/0_overview/insights.md`

Qualitaetssicherung und Betrieb

Aktuelle Guards: - `core_pipeline.py` mit `fast/full/both` Phasen. - SQL Assertions mit Error/Warn Trennung. - JSON/Markdown Reports unter `logs/core_validation/`.

Operatives Ziel: - Taeglicher Standardablauf: 1. Core Build + Validation 2. Mart Views anwenden 3. Dashboard Refresh

---

Offene Punkte

- Einheitliche Symbol-Normalisierung ueber alle Exchanges final absichern.
- Verbindliche Definition fuer "Connection Drop" dokumentieren.
- Zeit-Synchronisierung und Resampling-Regeln fuer Vergleichbarkeit fixieren.
- Dashboard Tests fuer SQL Contracts und leere Datenfenster hinzufuegen.

Roadmap (Naechste Schritte)

1. Dashboard Hardening
   - Integrations-/Smoke-Tests fuer Query Contracts
   - Runbook fuer taeglichen Refresh
2. Forecasting Contract
   - Feature- und Label-Fenster definieren
   - Train/Validation Split je Exchange/Symbol
3. Forecasting Baseline
   - Start mit klassischen Modellen (z. B. Ridge)
   - Danach Vergleich mit modernen Time-Series Modellen

Demo Kommando

```
pip install -r requirements.txt
streamlit run scripts/5_marts/dashboard_mvp_app.py
```

Danke.