Crypto DWH Leitfaden fuer Data Engineers

Crypto DWH Leitfaden fuer Data Engineers

Datenfluss, Verarbeitung, Deployment pro Schritt

Trainingsfolien fuer Data-Engineering-Auszubildende

- Datum: 2026-02-26
- Fokus: Von Rohdaten bis Data Mart und Dashboard

Lernziele

Nach dieser Session koennt ihr:

1. den End-to-End Datenfluss der Pipeline erklaeren.
2. pro Schritt Zweck, Input, Output und Deployment verstehen.
3. `OLTP` und `OLAP` in dieser Architektur korrekt einordnen.
4. `Star`, `Snowflake`, `Galaxy` und `Data Mart` am Projektbeispiel unterscheiden.

Agenda

1. Problem und Zielbild
2. Pipeline-Schritte mit Deployment-Diagrammen
3. ETL, OLTP, OLAP im Projektkontext
4. Data Mart + Schema-Patterns (Star/Snowflake/Galaxy)
5. Operativer Leitfaden fuer den taeglichen Betrieb

Problem und Zielbild

Problem

- Gleiche Coins haben je Exchange unterschiedliche Preise.
- Plattformqualitaet (Latency, Update-Frequenz, Disconnects) schwankt.
- Ohne saubere Zeitausrichtung sind Vergleiche nicht fair.

Zielbild

- Nachvollziehbare DWH-Pipeline von Ingestion bis Mart.
- Vergleichbare KPI je Symbol und Exchange.
- Dashboard als schneller Analysezugang.

End-to-End Datenfluss (Uebersicht)

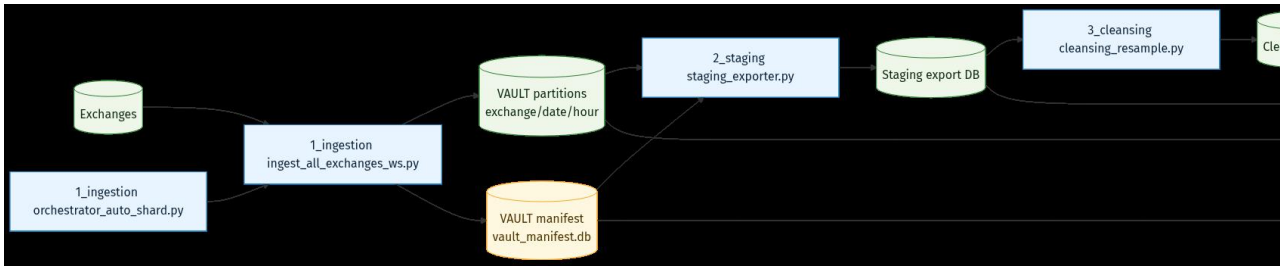

ETL/ELT in diesem Projekt

Praktische Sicht

- **E (Extract):** WebSocket-Ticks und Connection-Events aus Exchanges.
- **L (Load):** Zuerst in Raw-DBs (OLTP-nah, write-optimiert).
- **T (Transform):** In Staging/Cleansing/Core/Marts fuer Analyse.

Warum so?

- Online-Ingestion bleibt stabil.
- Batch-Transformationen koennen reproduzierbar laufen.

OLTP vs OLAP im Projekt

OLTP-Zone (schreibintensiv)

- `vault2/ingestion/exchange=<id>/date=<YYYY-MM-DD>/hour=<HH>/part_*.db`
- viele Inserts, laufender Betrieb, technische Rohdaten

OLAP-Zone (lese- und analyseintensiv)

- `cleaned_*.db`, `core_kpi.db`, Mart-Views/Cache
- aggregierte KPI, zeitliche Vergleiche, Dashboard-Abfragen

Schritt 1: Ingestion (Extract + Raw Load)

Verarbeitung

- Orchestrator shardet Exchanges auf Worker-Prozesse.
- Worker schreiben Ticks und Events kontinuierlich in SQLite.
- Restart- und Supervision-Logik stabilisiert den 24/7-Betrieb.

Ergebnis

- Rohdaten mit Ingestion-Timestamp als Basis fuer spaetere KPI.

Deployment

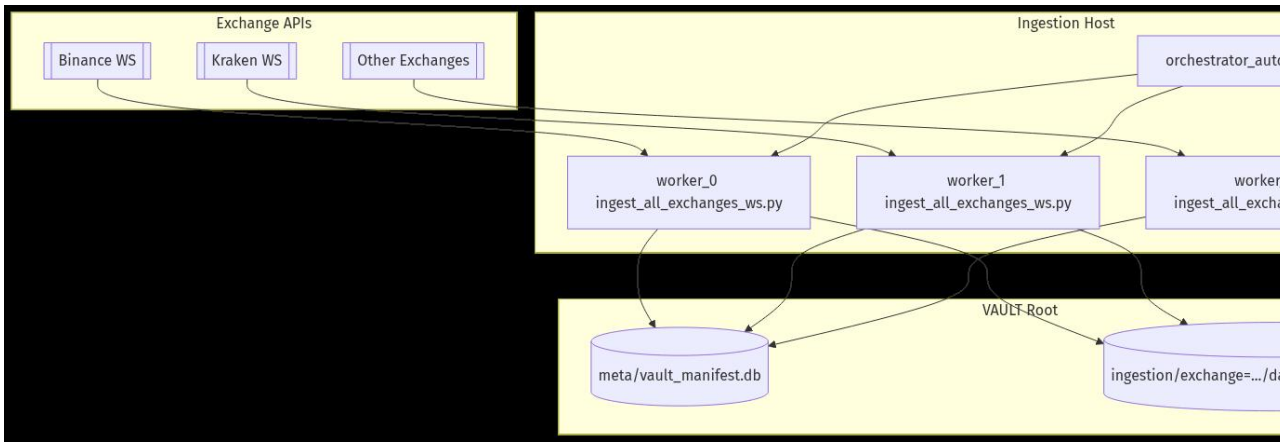

Schritt 2: Staging (Entkopplung)

Verarbeitung

- Geplanter Job exportiert ein Zeitfenster (z. B. letzte 24h).
- Optional inkrementell ueber Watermark-State.
- Lauf erzeugt Datenexport plus Metadaten-JSON.

Ergebnis

- Stabile Input-Scheibe fuer Cleansing und Core.

Deployment

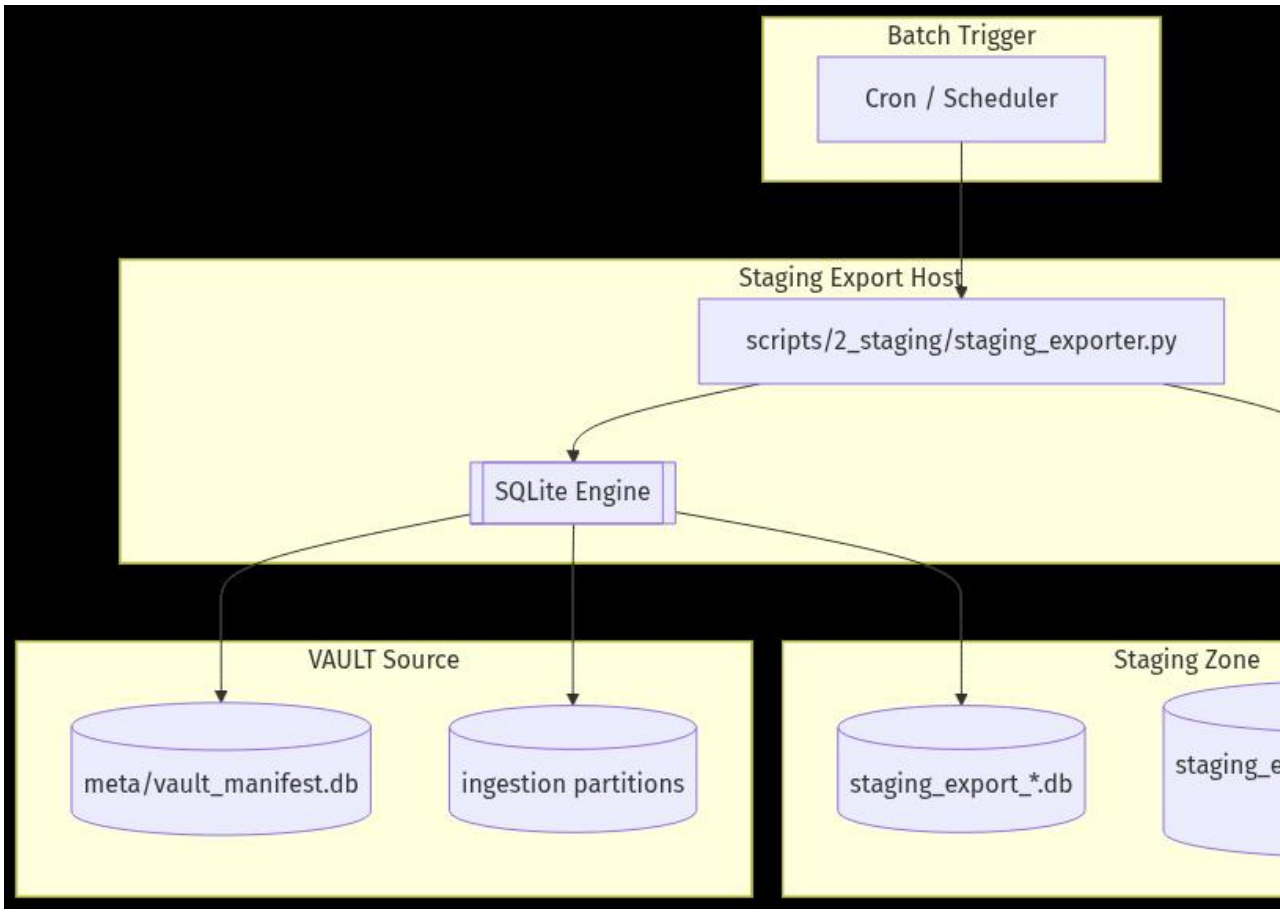

Schritt 3: Cleansing (Zeitliche Vergleichbarkeit)

Verarbeitung

- Resampling auf ein einheitliches Raster (z. B. 60s Bins).
- Fill-Strategien: `observed`, `forward_fill`, optional `interpolation`.
- Qualitaetsflags markieren `missing`, `stale`, Alter der Werte.

Ergebnis

- Vergleichbare Zeitreihen pro `(exchange_id, symbol)`.

Deployment

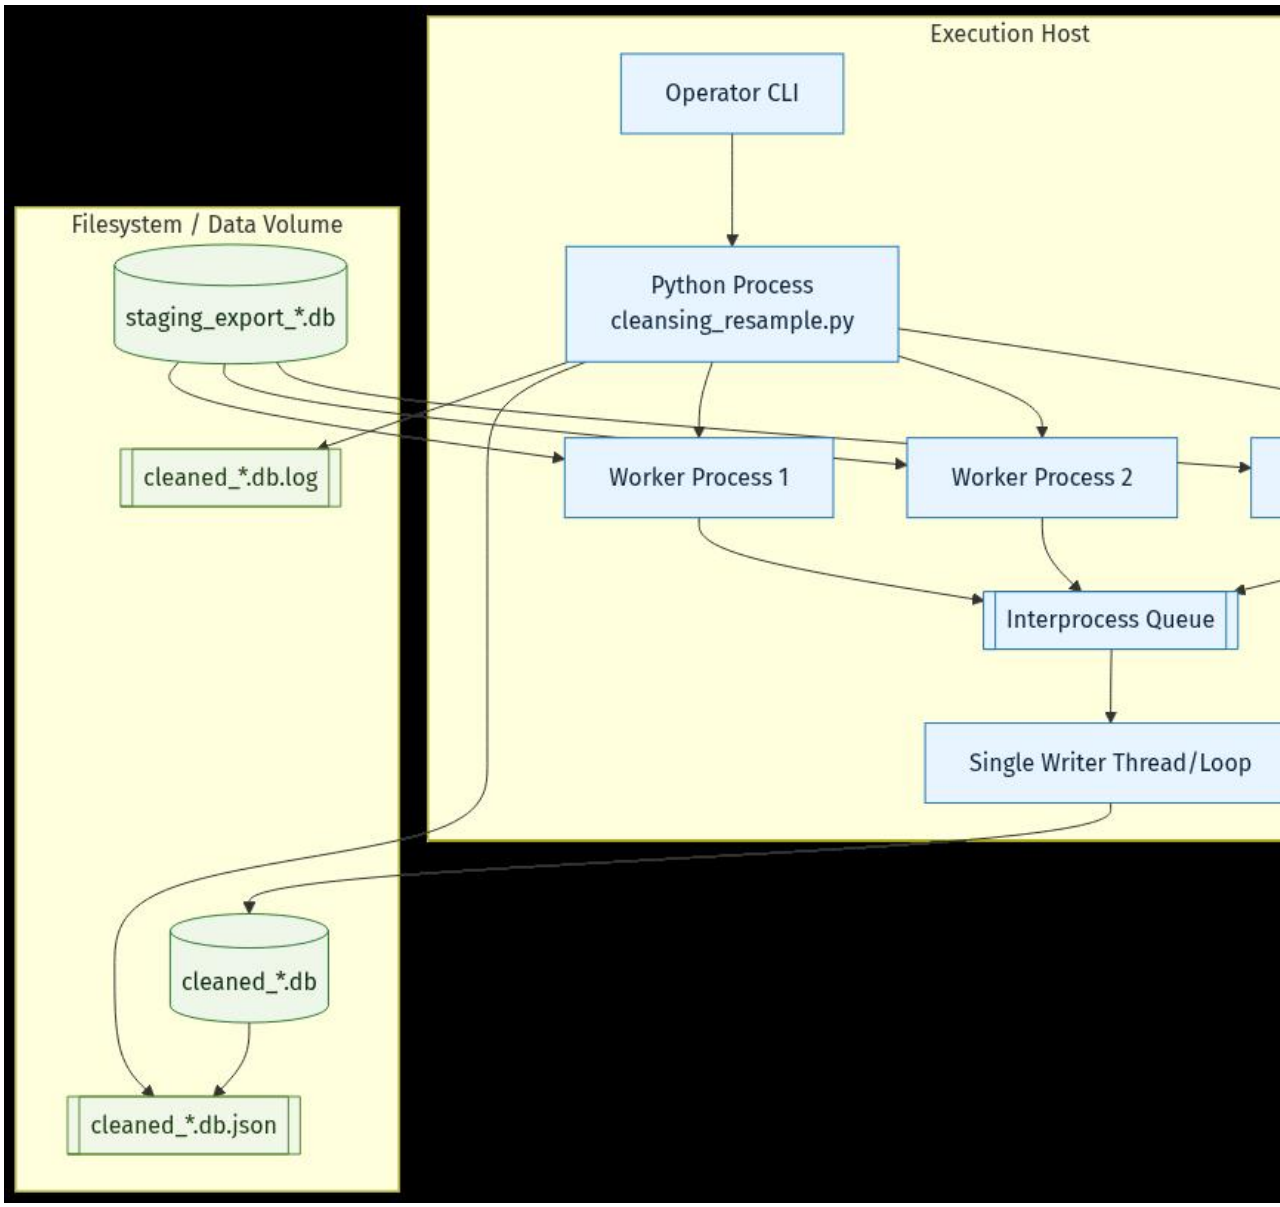
Execution Host
Operator CLI
Python Process
cleansing_resample.py
Worker Process 1
Worker Process 2
Interprocess Queue
Single Writer Thread/Loop
Filesystem / Data Volume
staging_export_*.db
cleaned_*.db.log
cleaned_*.db
cleaned_*.db.json

Schritt 4: Core (KPI-Berechnung, OLAP Kern)

Verarbeitung

- KPI-Views fuer:
  - `latency_ms`
  - `update_frequency_hz`
  - `disconnect_count`
  - `price_diff_abs` / `price_diff_pct`
- SQL Assertions validieren Datenqualitaet und Vollstaendigkeit.

Ergebnis

- Konsistente KPI-Schicht als Single Source of Truth.

Deployment

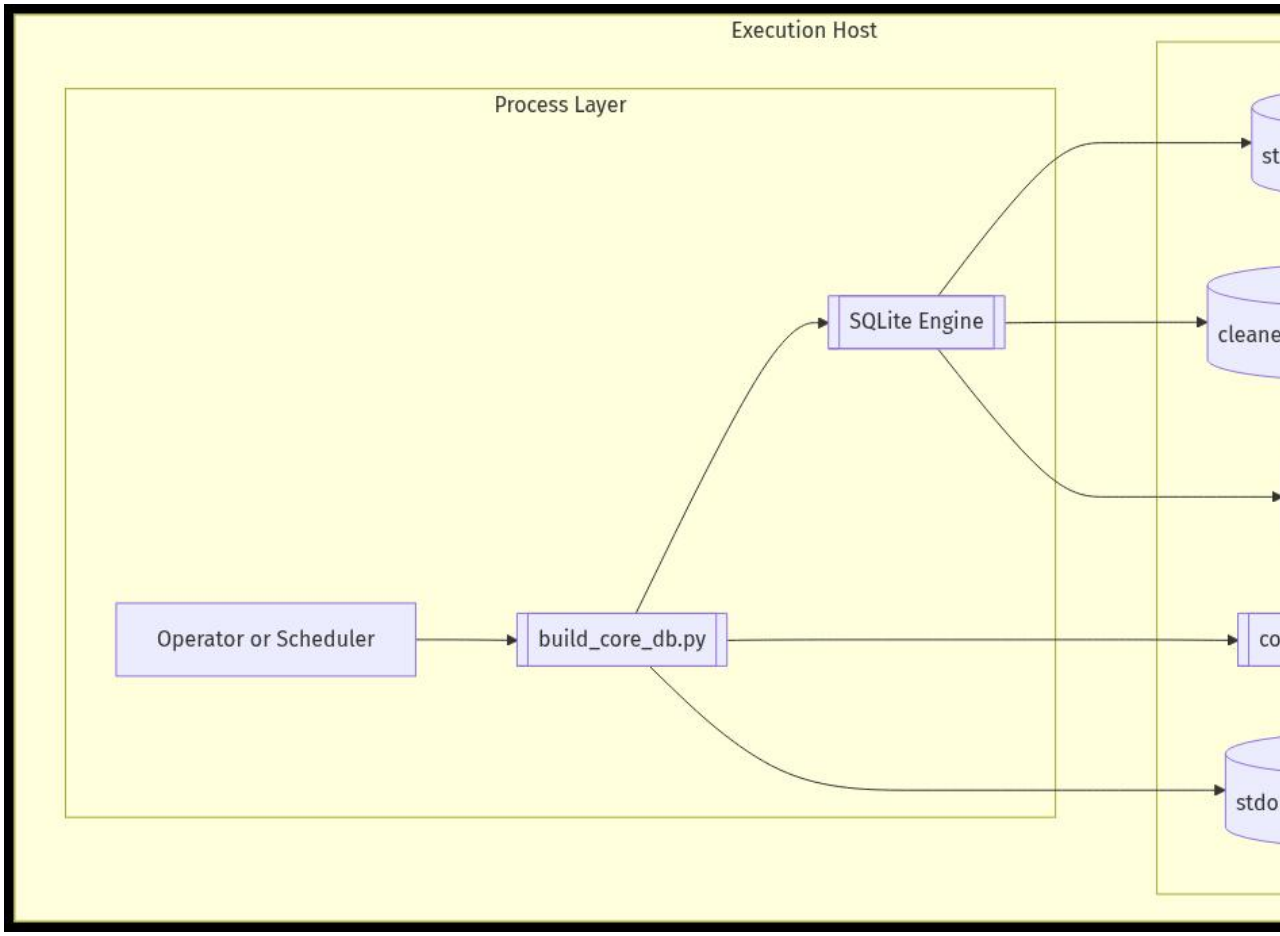

Schritt 5: Marts (Analyse-Verbrauchsschicht)

Verarbeitung

- Mart-Views formen KPI fuer konkrete Analysefragen um.
- Dashboard liest nur konsumfertige Views/Cache-Tabellen.
- Keine KPI-Neuberechnung in der UI.

Ergebnis

- Schnelle, konsistente Auswertung fuer Fachnutzer.

Deployment

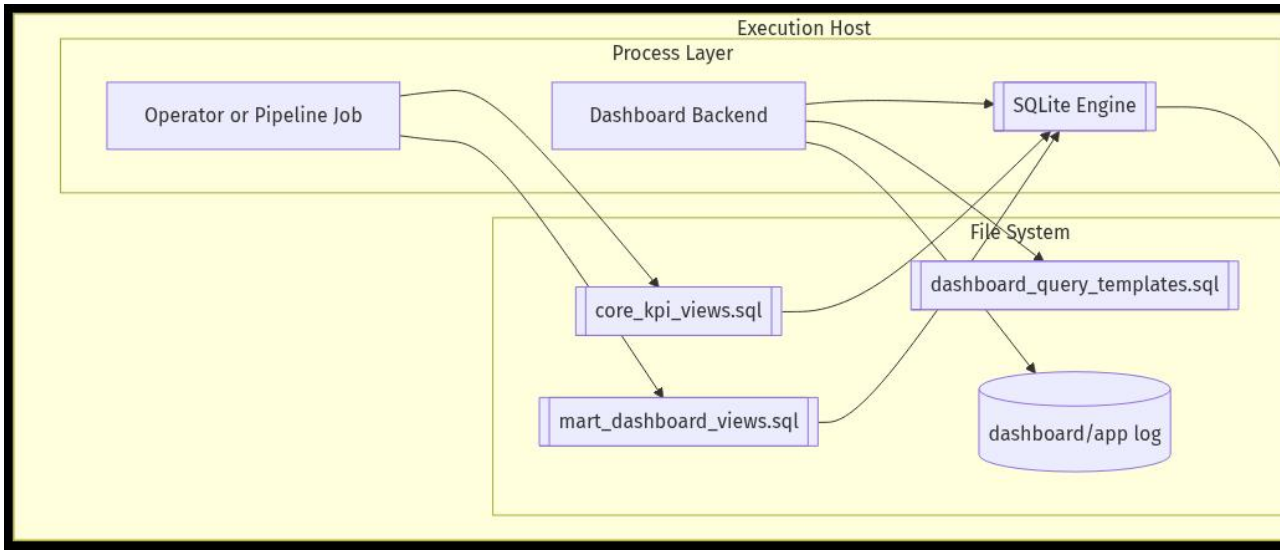

Data Mart im Projekt

Was ist der Data Mart hier?

- Themenbezogener Ausschnitt fuer Dashboard-Konsum.
- Fokus: Preisabweichung und Plattformqualitaet.

Konkrete Objekte

- `vw_mart_dashboard_platform_quality_daily`

- `vw_mart_dashboard_price_deviation_daily`
- `vw_mart_dashboard_price_curve_24h_binance`

Star Schema (einfach, schnell konsumierbar)

Empfehlung: - fuer stabile Dashboard-KPI mit klaren Dimensionen.

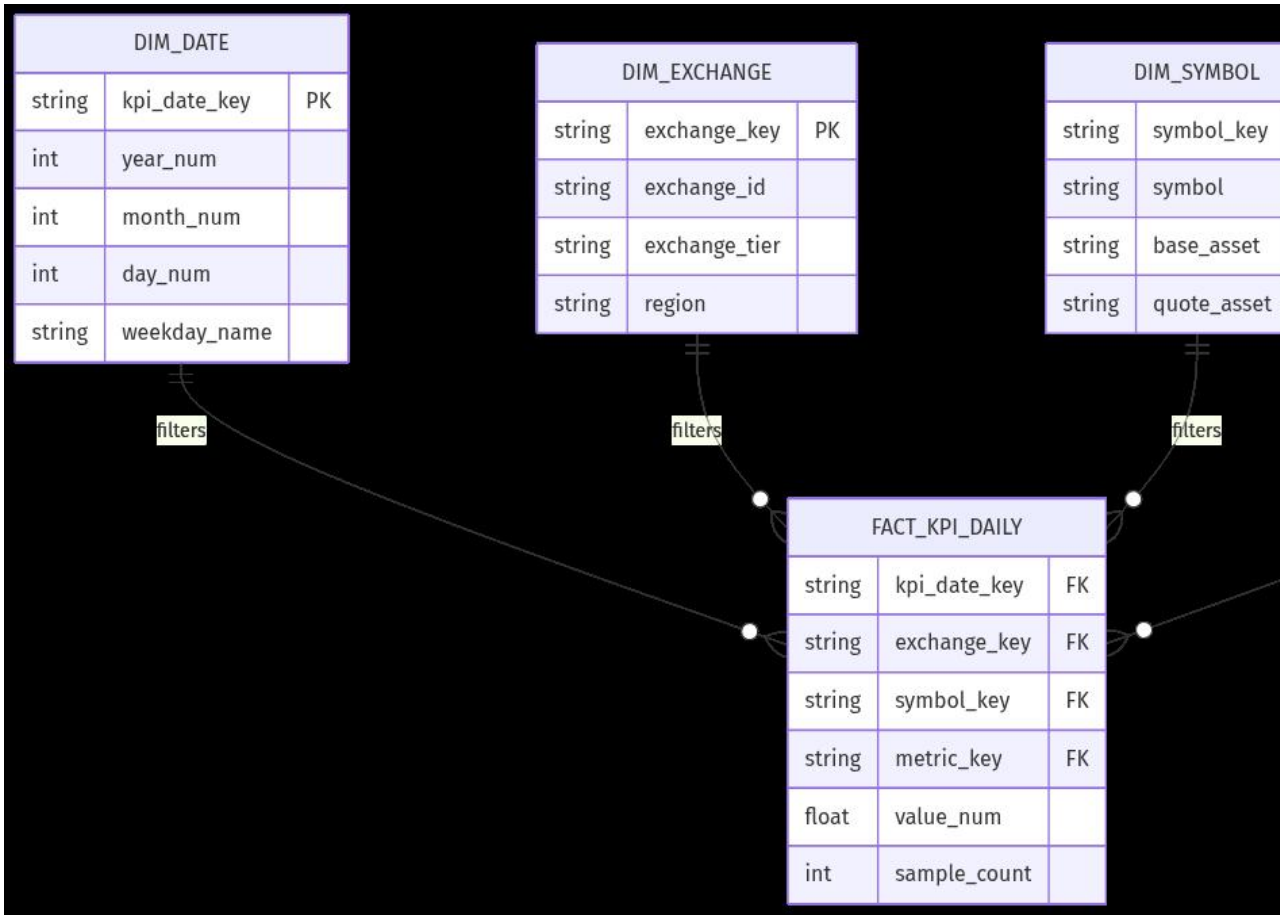

Snowflake Schema (staerker normalisiert)

Empfehlung: - wenn Dimensionen wachsen und Redundanz gesenkt werden soll.

Trade-off: - weniger Duplikate, aber komplexere Joins.

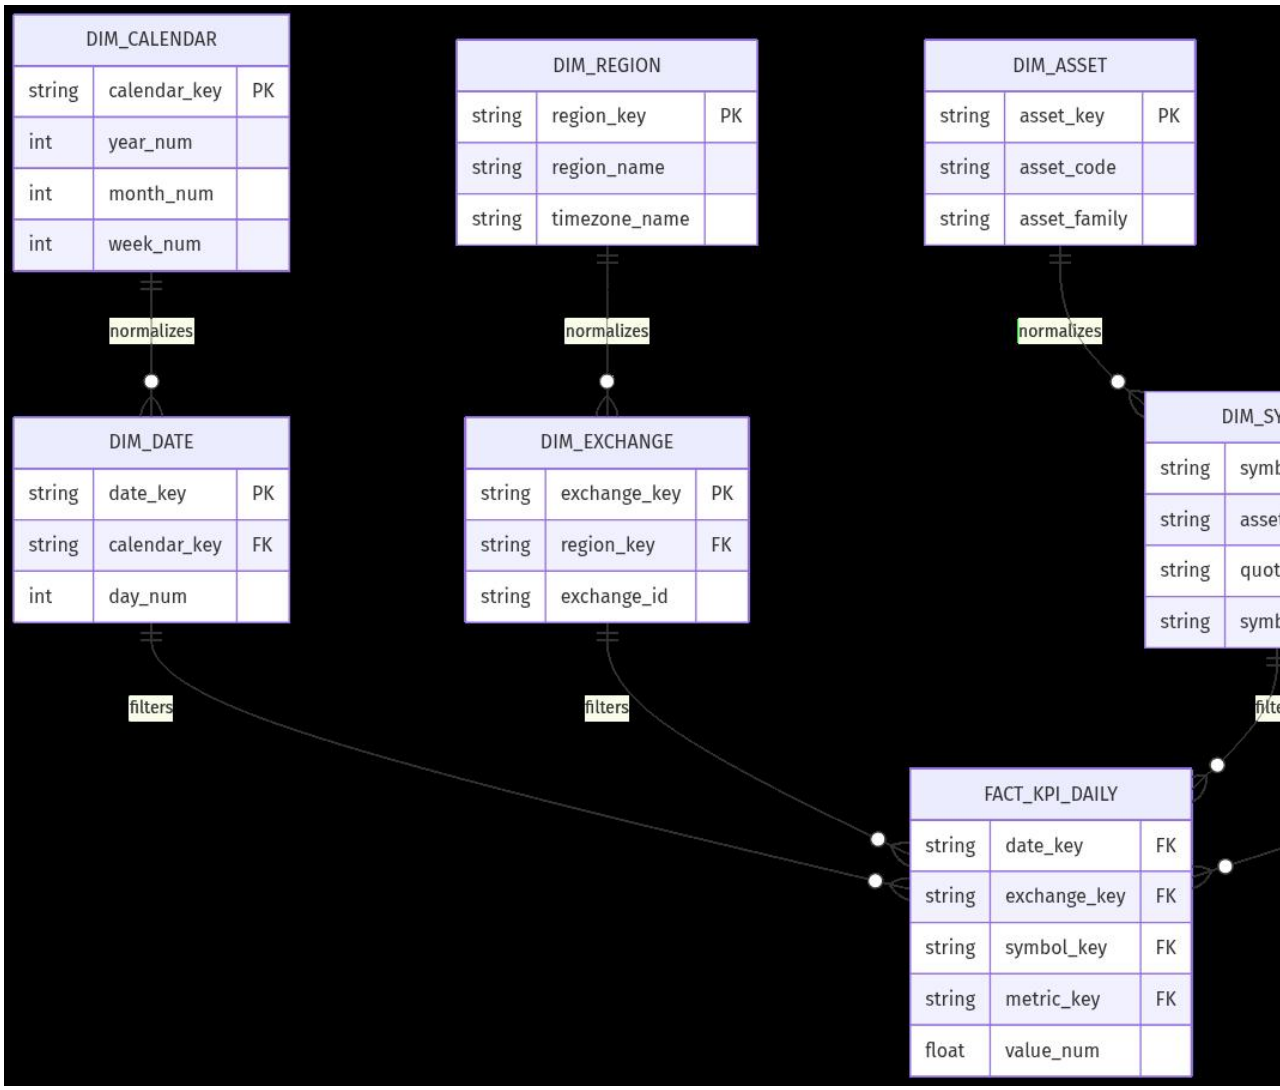

Galaxy Schema (mehrere Facts, geteilte Dimensionen)

Empfehlung: - wenn mehrere Analysebereiche parallel laufen. - hier: Plattformqualitaet und Preisabweichung als getrennte Facts.

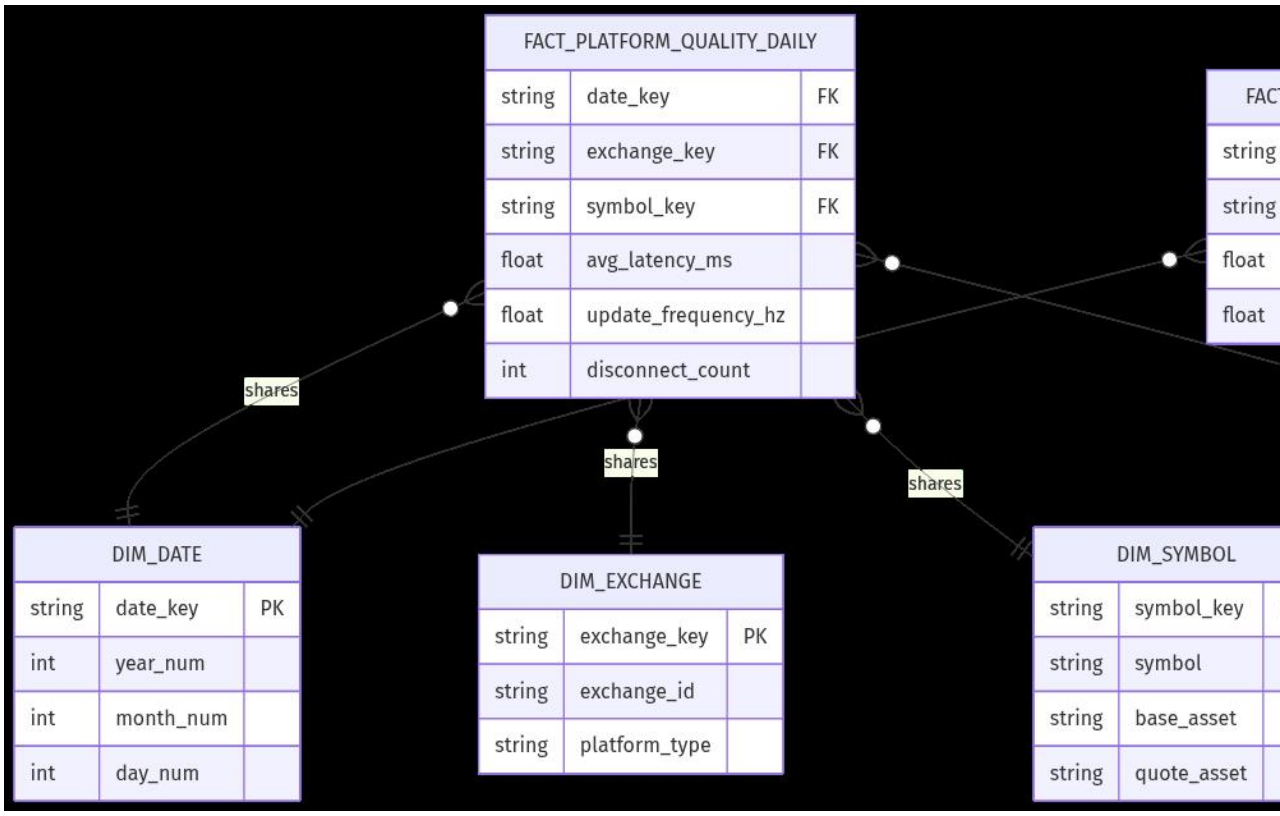

Wann welches Schema?

1. **Star**: Startpunkt fuer MVP-Dashboard, einfache SQL, schnelle Lieferung.
2. **Snowflake**: bei vielen Dimension-Attributen und Governance-Fokus.
3. **Galaxy**: bei mehreren Fact-Domaenen mit gemeinsamen Dimensionen.

Praxisempfehlung: - MVP mit Star starten, bei Bedarf zu Snowflake/Galaxy evolvieren.

Operativer Leitfaden (taeglicher Ablauf)

1. Ingestion laeuft kontinuierlich (Health und Disconnects beobachten).
2. Staging exportiert den Zielzeitraum.
3. Cleansing erzeugt zeitlich ausgerichtete Serien.
4. Core berechnet/validiert KPI.
5. Mart-Views und Cache refreshen.

6. Dashboard fuer Analyse freigeben.

Qualitaets-Checkliste fuer Auszubildende

- Sind alle Zeitstempel in UTC?
- Ist Symbol-Mapping exchange-uebergreifend konsistent?
- Sind Missing/Stale-Werte sichtbar markiert?
- Ist die Definition von "Connection Drop" dokumentiert?
- Werden KPI nur im SQL-Layer gerechnet (nicht in UI)?

PDF-Erzeugung aus Markdown

Beispiel mit Marp CLI:

```
npx @marp-team/marp-cli docs/7_presentation/crypto_dwh_data_engineering_leitfaden_slides.md
```

Die Datei ist Marp-kompatibel und fuer direkten PDF-Export vorbereitet.